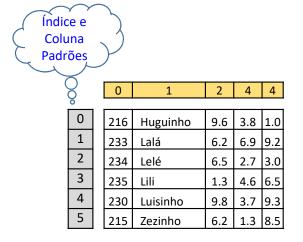


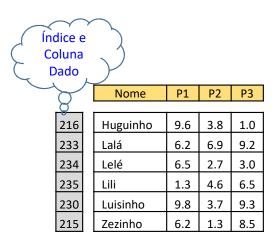
DataFrame

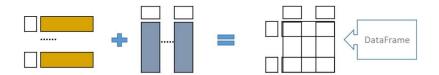


DataFrames do Pandas

DataFrames: estrutura bidimensional indexada que armazena valores de qualquer tipo.





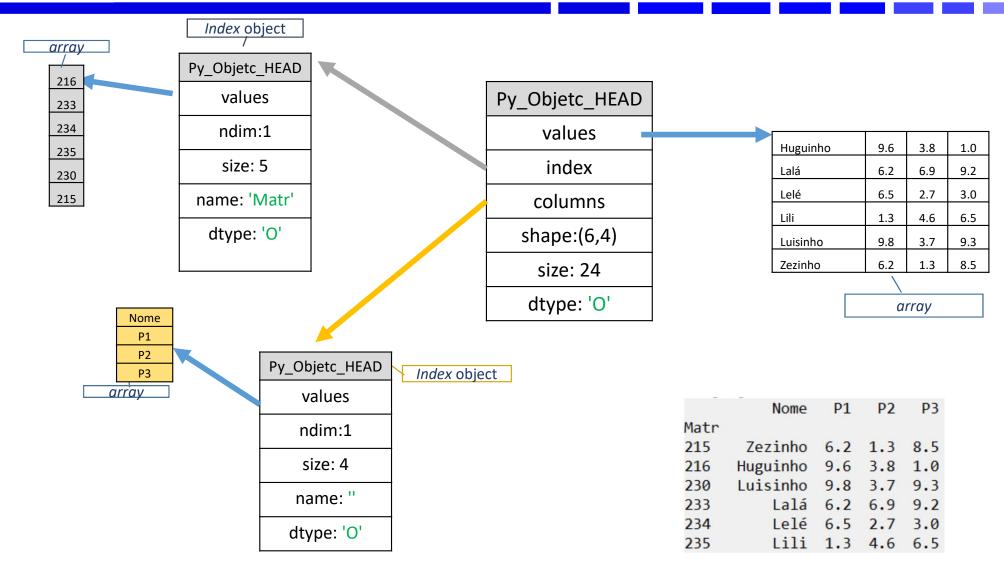


Estrutura tabular com linhas e colunas, similar a uma planilha, composta por:

- valores: array bidimensional (estruturado ou homogêneo), dicionário (que pode conter df, arrays, constants ou objetos do tipo lista) ou DataFrame
- <u>índices</u>: uma sequência de números ou rótulos (labels) quaisquer que identificam as linhas
- <u>colunas</u>: uma sequência de números ou rótulos (*labels*) quaisquer que identificam as colunas
- ✓ Os índices e as colunas não precisam ser exclusivos. Por padrão, variam de 0 a itens -1



Esquema simplificado do objeto DataFrame





Atributos e Exibição

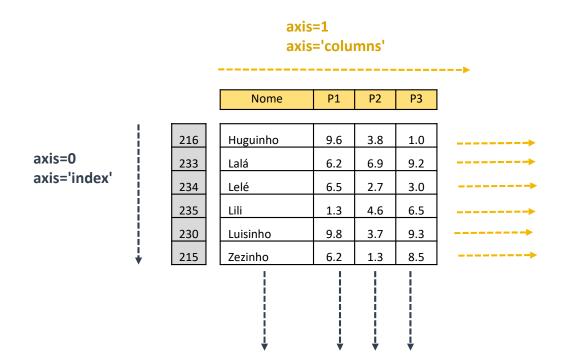
Valores	df.values
Formato	df.shape
qt de valores	df.size
Transposta	df.T
Labels dos Índices	df.index
Nome do obj index	df.index.name
Labels das colunas	df.columns
Nome do obj columns	df.columns.name
Inf. da estrutura	df.info()
Primeiros Elementos	<pre>df.head(n) default, n=5</pre>
Últimos Elementos	<pre>df.tail(n) default, n=5</pre>
Resumos Estatísticos das colunas numéricas	df.describe()



DataFrames do Pandas

Estrutura tabular com linhas e colunas, similar a uma planilha, composta por:

- ✓ "grupo de Series que compartilham um índice (nome das colunas)" ou
- ✓ "um dicionário de Series"





Alterando nome de um eixo (lista de colunas/linhas)

Sintaxe:

```
df.rename_axis (mapper, axis=0, inplace=False)
```

Altera o nome do index ou columns. Retorna um DataFrame com o nome da lista de colunas/linhas alterado

```
mapper - valor que será o nome do eixo (escalar, list-like)
```

axis = n/nome – eixo a renomear. Padrão: 0 (altera o nome do *index*). Pode ser o nome do eixo

inplace = False/True. Padrão: False. Com inplace=True, realiza a operação no DataFrame, não cria uma cópia.

```
df: Matr P1 P2 P3

Nome
Lalá 133 6.2 6.9 9.2
Lelé 131 6.5 2.7 3.0
```

```
df.rename_axis("AL",axis=1,inplace=True)
# equivalente a:
#    dfNtd.rename_axis("AL",axis="columns",inplace=True)
#    dfNtd.columns.name='AL'

AL    Matr    P1    P2    P3
    NOME
    Lalá    133    6.2    6.9    9.2
    Lelé    131    6.5    2.7    3.0
```



pd.DataFrame (...)

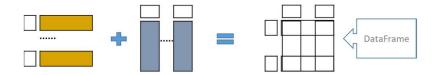


DataFrames do Pandas

DataFrames: estrutura bidimensional indexada que armazena valores de qualquer tipo.

	0	1	2	4	4
0	216	Huguinho	9.6	3.8	1.0
1	233	Lalá	6.2	6.9	9.2
2	234	Lelé	6.5	2.7	3.0
3	235	Lili	1.3	4.6	6.5
4	230	Luisinho	9.8	3.7	9.3
5	215	Zezinho	6.2	1.3	8.5

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5



Estrutura tabular com linhas e colunas, similar a uma planilha, composta por:

- valores: array bidimensional (estruturado ou homogêneo), dicionário (que pode conter Series, arrays, constants ou objetos do tipo lista) ou DataFrame
- <u>índices</u>: uma sequência de números ou rótulos (labels) quaisquer que identificam as linhas
- <u>colunas</u>: uma sequência de números ou rótulos (*labels*) quaisquer que identificam as colunas
- ✓ Os índices e as colunas não precisam ser exclusivos. Por padrão, variam de 0 a itens -1



Sintaxe:

pd.DataFrame(valores)

```
# a partir do dicionário de listas
>>>dNtB= {
    'Lalá : [133,6.2,6.9,9.2],
    Lelé': [131,6.5,2.7,None] }

>>>dfNtB= pd.DataFrame(dNtB)
>>>dfNtB
    Lalá    Lelé
0    133.0    131.0
1    6.2    6.5
2    6.9    2.7
3    9.2    NaN
```

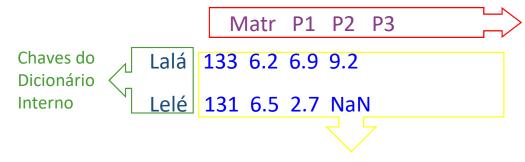


a partir de dicionário de dicionários

>>>dfNtC= pd.DataFrame(dNtC)

>>>dfNtC

#casamento pelas chaves



Valores das Chaves do Dicionário interno

Chaves do Dicionário Externo

PASSO A PASSO – Casamento pelas chaves

a partir de dicionário de dicionários



```
# a partir de dicionário de dicionários
dNtD= { 'Lalá':{'Matr': 133,'P1': 6.2,'P2': 6.9,'P3': 9.2 },
         'Lelé':{'Matr': 131,'P1': 6.5,'P2': 2.7
>>>dfNtD= pd.DataFrame(dNtD)
>>>dfNtD
                 #casamento pela chave
                       Lalá Lelé
               Matr 133.0 131.0
                     6.2
               P1
                           6.5
               P2
                     6.9 2.7
                     9.2
               P3
                           NaN
```

a partir de dicionário de Series, index indefinido

```
    Nome:
    Matr:
    P1:
    P2:
    P3:

    0 Lalá
    0 133
    0 6.2
    0 6.9
    0 9.2

    1 Lelé
    1 131
    1 6.5
    1 2.7
```

```
dfNtSs= pd.DataFrame (dNtSs)

>>>dfNtSs #casamento pelo index

    Matr Nome P1 P2 P3

0 133 Lalá 6.2 6.9 9.2

1 131 Lelé 6.5 2.7 NaN
```



a partir de dicionário de Series, index definido

```
      Matr :
      P1 :
      P2 :
      P3 :

      Lalá 133
      Lalá 6.2
      Lalá 6.9
      Lalá 9.2

      Lelé 131
      Lelé 6.5
      Lelé 2.7
      Lelé: 3.0
```

```
dfNtSi= pd.DataFrame(dNtSi)
```

>>>dfNtSi #casamento pelo index

```
Matr P1 P2 P3

Lalá 133 6.2 6.9 9.2

Lelé 131 6.5 2.7 3.0
```

com especificação de índices e/ou colunas

Sintaxe:

```
pd.DataFrame(valores, index=array1d, columns=array1d)
```

a partir de uma lista

```
INtA=[['Lalá',133,6.2,6.9,9.2], ['Lelé',131,6.5,2.7,3.0]]
ind = ['Lalá', 'Lelé']
cols = ['Nome', 'Matr', 'P1', 'P2', 'P3']
>>>dfNtAic= pd.DataFrame( lNtA , index=ind, columns=cols)
>>> dfNtAic
    Nome Matr P1 P2 P3
Lalá Lalá 133 6.2 6.9 9.2
Lelé Lelé 131 6.5 2.7 3.0
>>>dfNtAc= pd.DataFrame( lNtA ,columns=cols)
>>> dfNtAc
  Nome Matr P1 P2 P3
 Lalá 133 6.2 6.9 9.2
1 Lelé 131
            6.5 2.7 3.0
```

com 1ª planilha de um arquivo Excel

Sintaxe:

```
pd.read excel(caminho, index_col= n, header= n)
```

caminho - localização do arquivo: composto pelo caminho (absoluto/relativo) e nome

index_col = n – O número da <u>coluna</u> do arquivo a ser usada como <u>labels</u> das linhas (índice). O padrão é None (o arquivo não possui tal coluna)

header = n - O número da linha para os labels das colunas (padrão é 0) ou None quando não há tal linha

decimal = ',' - quando o separador de casas decimais é a vírgula, Padrão: '.'

dfNtA=pd.read_excel("als.xlsx")
print(dfNtA.head(2))

	Nome	Matr	P1	P2	Р3	
0	Lalá	133	6.2	6.9	9.2	
1	Lelé	131	6.5	2.7	3.0	

als.xlsx

À	Α	В	С	D	E	
1	Nome	Matr	P1	P2	P3	Ī
2	Lalá	133	6,2	6,9	9,2	
3	Lelé	131	6,5	2,7	3,0	
						т.

Arquivo na mesma pasta do arq .py



dfNt2=pd.read_excel("als.xlsx", index_col=0)
print(dfNt2.head(2))

	Matr	P1	P2	Р3
Nome				
Lalá	133	6.2	6.9	9.2
Lelé	131	6.5	2.7	3.0

dfNt3=pd.read_excel("als.xlsx",index_col=1')
print(dfNt3.head(2))

	Nome	P1	P2	Р3
Matr				
133	Lalá	6.2	6.9	9.2
131	Lelé	6.5	2.7	3.0

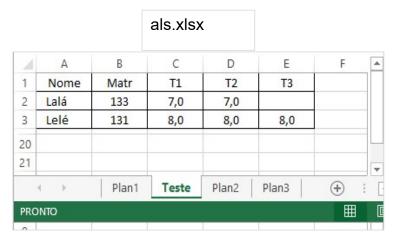
		als.x			
A	A	В	С	D	E
1	Nome	Matr	P1	P2	P3
2	Lalá	133	6,2	6,9	9,2
3	Lelé	131	6,5	2,7	3,0



com planilha *nomeada* de um arquivo Excel

dfNTesA=pd.read_excel("als.xlsx", sheet_name='Teste',index_col=0)
print(dfNTesA.head(2))

	Matr	Т1	Т2	Т3
Nome				
Lalá	133	7	7	NaN
Lelé	131	8	8	8.0



dfNTesB=pd.read_excel("als.xlsx", sheet_name='Teste', index_col=1)
print(dfNTesB.head(2))

	Nome	T1	T2	Т3
Matr				
133	Lalá	7	7	NaN
131	Lelé	8	8	8.0



Métodos Úteis

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

* com inplace=True, realiza a operação no DF, não cria uma cópia

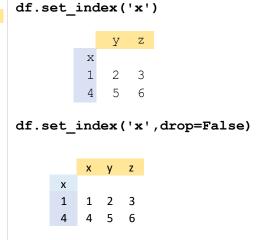
<pre>df.sort_values(by,axis=0,ascending=True,na_position='last') *</pre>	Retorna uma cópia do DataFrame ordenado pelos valores by = nomes ou lista de nomes para ordenar. Se axis=0 os nomes se referem a colunas. Se axis=1 os nomes se referem a linhas na_position = 'last' / 'first', coloca NaN no final/ início
<pre>df.sort_index(axis=0, level=None, ascending=True, sort_remaining=True) *</pre>	Retorna uma cópia do <i>DataFrame</i> ordenado pelos labels do índice sort_remaining - Se True e o índice é multinível, classifica também pelos outros níveis (em ordem) após classificar pelo nível especificado.
<pre>df.rename(mapper=None, axis= n/str, index=None, columns=None) *</pre>	Altera o nome do <i>index</i> ou <i>columns</i> . Retorna um <i>DataFrame</i> com o nome da lista de colunas/linhas alterado Mapper,index,columns - um dicionário ou função que é aplicado para transformar os valores do eixo. Usar mapper e axis para especificar o eixo ou index/columns
	<pre>axis = n/nome - eixo a renomear. Padrão: 0 (altera o nome do index). Pode ser o nome do eixo df.rename(columns=str.upper,index={216:2,215:1})</pre>

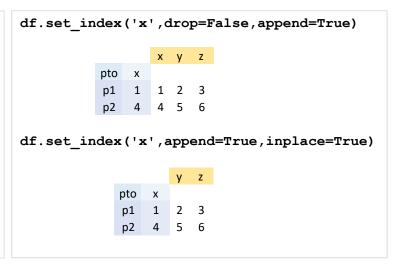


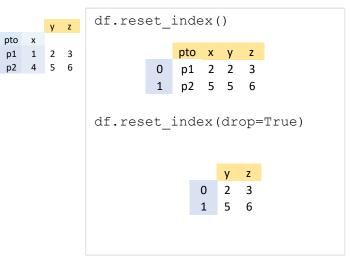
Métodos Úteis: set_index e reset_index

<pre>df.set_index((keys, drop=True, append=False, inplace=False, verify_integrity=False)*</pre>	Define uma lista/Series/Df como o <i>index</i> de um DataFrame keys - nome da coluna ou lista de colunas drop - a coluna usada para o <i>index</i> é descartada, se True append =-anexa a coluna ao <i>index</i> existente se True, verify_integrity -verifica se a nova coluna do <i>index</i> está duplicada, se True.
<pre>df.reset_index(level=None, drop=False, inplace=False, col_level=0, col_fill=") *</pre>	Redefine o <i>index</i> para o automático(<i>0 a n-1</i>) level - int, string ou lista - os seleciona e remove do <i>index</i> . drop - o <i>index</i> é adicionado como coluna de dados, se False col_level =-seleciona o nível de <i>columns a</i> inserir os rótulos., col_fill -objeto para determinar o nome dos outros níveis









pto x



Acessar/Alterar ou Incluir/Excluir



Acesso

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

	Nome	P1	P2	P3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

Nome	P1	P2	P3
Huguinho	9.6	3.8	1.0
Lalá	6.2	6.9	9.2
Lelé	6.5	2.7	3.0
Lili	1.3	4.6	6.5
Luisinho	9.8	3.7	9.3
Zezinho	6.2	1.3	8.5
	Huguinho Lalá Lelé Lili Luisinho	Huguinho 9.6 Lalá 6.2 Lelé 6.5 Lili 1.3 Luisinho 9.8	Huguinho 9.6 3.8 Lalá 6.2 6.9 Lelé 6.5 2.7 Lili 1.3 4.6 Luisinho 9.8 3.7

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

A c e s	Coluna	df[coluna] ou df.coluna df[lista de colunas]	Retorna uma <i>Series</i> com os valores da <i>coluna</i> ou um <i>DataFrame</i> com os elementos da <i>lista de colunas</i>
	Linha	df.loc[índice] ou df.loc[lista de índices] df.iloc[posição] df.iloc[lista de posições]	Retorna uma Serie com os valores da linha indexada por <i>índice</i> ou um <i>DataFrame</i> com os elementos da <i>lista de índices</i> . .loc para os índices criados, .iloc para a posição no índice
s o	Elemento ou Dice	<pre>df.loc[indice][coluna] ou df.loc[lista de inds][lista de cols]* df[coluna].loc[indice] ou df[lista de cols].loc[lista de inds]*</pre>	Retorna o valor do elemento indexado por <i>índice, coluna</i> ou uma nova Series com os elementos da <i>lista de índices/colunas</i> . * Para posição no índice deve ser usado .iloc



Mãos na Massa

Considere o Dataframe G:

	Matr	P1	P2	Р3
Lalá	133	6.2	6.9	9.2
Lelé	131	6.5	2.7	3.0
Lili	135	1.3	4.6	6.5

Qual o resultado das seguintes seleções?

```
1) G[['P1', 'P3']].iloc[2]
```

- 2) G['Lalá']
- 3) G.T['Lalá']
- 4) G.T[['Lalá','Lili']].iloc[0:2].T

```
1)
   P1
         1.3
   P3 6.5
  Name: Lili, dtype: float64
                          Series
2) KeyError: 'Lalá'
3)
   Matr 133
   P1 6.2
   P2
           6.9
   P3 9.2
  Name: Lalá, dtype: object
                           Series
4)
      Matr P1
Lalá 133 6.2
Lili 135 1.3
                          DataFrame
```



Incluir ou Alterar

	Nome	P1	P2	Р3
			,	
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

Nome	P1	P2	Р3
Huguinho	9.6	3.8	1.0
Lalá	6.2	6.9	9.2
Lelé	6.5	2.7	3.0
Lili	1.3	4.6	6.5
Luisinho	9.8	3.7	9.3
Zezinho	6.2	1.3	8.5
	Huguinho Lalá Lelé Lili Luisinho	Huguinho 9.6 Lalá 6.2 Lelé 6.5 Lili 1.3 Luisinho 9.8	Huguinho 9.6 3.8 Lalá 6.2 6.9 Lelé 6.5 2.7 Lili 1.3 4.6 Luisinho 9.8 3.7

Nome	P1	P2	Р3
Huguinho	9.6	3.8	1.0
Lalá	6.2	6.9	9.2
Lelé	6.5	2.7	3.0
Lili	1.3	4.6	6.5
Luisinho	9.8	3.7	9.3
Zezinho	6.2	1.3	8.5
	Huguinho Lalá Lelé Lili Luisinho	Huguinho 9.6 Lalá 6.2 Lelé 6.5 Lili 1.3 Luisinho 9.8	Huguinho 9.6 3.8 Lalá 6.2 6.9 Lelé 6.5 2.7 Lili 1.3 4.6 Luisinho 9.8 3.7

I n	I n	Coluna	<pre>df[coluna] ou df.coluna = valor df[lista de colunas] = valor ou Series</pre>	Altera o valor/valores do(s) elemento(s) indexado(s) por <i>coluna/lista de colunas</i> . Se a coluna não existe, é incluída.
	c - A I t	Linha	<pre>df.loc[indice] =valor df.loc[lista de indices] = valor ou Series df.iloc[posição] =valor df.iloc[lista de posições] = valor ou Series</pre>	Altera o valor/valores do elemento(s) indexado(s) por <i>índice/lista de índices</i> . Se o índice não existe, é incluído.
-	A I t	Elemento ou Dice	df.loc[índice,coluna]=valor ou df.loc[lista de índs,lista de cols] = valor	Altera o valor/valores do elemento(s) indexado(s) por índice/lista de índices e coluna/lista de colunas

24



Excluir

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

	Nome	P1	P2	Р3
216	Huguinho	9.6	3.8	1.0
233	Lalá	6.2	6.9	9.2
234	Lelé	6.5	2.7	3.0
235	Lili	1.3	4.6	6.5
230	Luisinho	9.8	3.7	9.3
215	Zezinho	6.2	1.3	8.5

E X C	Coluna	<pre>df.drop(coluna,axis=1)* ou df.drop(lista de colunas,axis=1)*</pre>	retorna uma cópia do DataFrame sem a coluna/Icolunas especificadas
u i r	Linha	<pre>df.drop(indice) ou df.drop(lista de indices)*</pre>	retorna uma cópia do DataFrame sem a linha/linhas especificadas

^{*} com inplace=True, realiza a operação na Series, <u>não</u> cria uma cópia





Medidas de Tendência Central

Média: df.mean() ^[1]	>>>df.mean() x 13.333333 y 20.000000 z 16.666667
	>>>df.mean(axis=1) p1 20.0 p2 10.0 p3 20.0
Mediana: df.median() ^[1]	>>>df.median() x 10.0 y 20.0 z 10.0
Moda: df.mode() ^[1]	>>>df.mode()

```
df:
    x    y    z
    p1    10    20    30
    p2    10    10    10
    p3    20    30    10
```

1 - Com axis=1, operação por linha
 2 - Operação aceita nos atributos index e columns



Medidas de Tendência Central

```
Máximo: df.max() [1][2]
                                           >>>df.max(axis=1)
                                                   30
Mínimo: df.min()^{[1][2]}
                                           р1
                                           p2
                                                  10
Índice 1º Mínimo: df.idxmin()
                                                  30
                                           p3
Índice 1º Máximo: df.idxmax()
                                           dtype: int64
                                           >>>df.min()
                                                 10
                                                 10
                                                 10
                                           dtype: int64
                                           >>>df.quantile(axis=1)
Quantil:
                                                  20.0
                                           р1
df.quantile (q=\%)^{[1]}
                                           р2
                                                  10.0
        padrão q=0.5
                                           р3
                                                  20.0
```

```
df:
    x    y    z
    p1    10    20    30
    p2    10    10    10
    p3    20    30    10
```

```
1 – Com axis=1, operação por linha
```

^{2 –} Operação aceita nos atributos index e columns



Medidas de Dispersão

Variância: df.var() ^[1]	>>>df.var() x 33.333333 y 100.000000 z 133.333333 dtype: float64
Desvio Padrão: df.std() ^[1]	>>>df.std() x 5.773503 y 10.000000 z 11.547005 dtype: float64

```
df:
    x    y    z
    p1    10    20    30
    p2    10    10    10
    p3    20    30    10
```

1- Com axis=1, operação por linha

2 – Operação aceita nos atributos index e columns